

Технически Университет Варна, катедра СИТ

Компютърни мрежи и Интернет - лабораторно упражнение №3

Оптимално кодиране (компресия) на информация

I. ТЕОРЕТИЧНИ СВЕДЕНИЯ

Една от основните операции, които се изпълняват в комуникационните системи е процесът *кодиране*. В най-общия си смисъл, кодирането е **промяна на представянето на информация**, която има за цел да подобри характеристики на комуникационните системи, като например скорост при пренос на информация, достоверност при пренос на информация и т.н. Съществуват няколко вида кодирания: АЦП кодиране (цифровизация), оптимално кодиране (компресия), шумоустойчиво кодиране, кодиране запазващо конфиденциалността на информацията (криптиране). В настоящото упражнение се засяга оптималното кодиране.

Оптималното кодиране се разделя на *lossless* (кодиране, при извършването на което не се губи информация – количеството информация, което се съдържа в съобщението, не се променя при подлагане съобщението на кодиране) и *lossy* (кодиране, при извършването на което се губи известно количество информация). Известно е, че *lossless* кодирането се прилага върху даннов тип информация, *lossy* кодирането върху информация от тип изображение и звук. В това упражнение ще се запознаем само с *lossless* кодирането и по-точно с най-базовите и широко известни методи за извършване на този процес.

Всеки реален източник на съобщения с ентропия H има значителен информационен излишък R , който се дължи на статистическите връзки между отделните символи и групи от символи и който улеснява предаването на информация в неидеални условия. В случай, че съобщенията се предават по идеален канал, информационният излишък става ненужен и предаването на тази, да я наречем излишна, информация само натоварва допълнително канала и води до неефективното му използване. Поставя се въпросът: не може ли по някакъв начин (чрез кодиране например) предаването съобщение да се освободи от информационния му излишък и така да се повиши скоростта на предаване на информацията? Във връзка с това възникват и следните въпроси: доколко може да се повиши скоростта на предаване на информацията и как да се извърши кодирането. Отговор на първите два въпроса дава теоремата на Шенон за кодирането на съобщенията в канали без шум, а на третия въпрос – методите на Шенон-Фано и на Хафман за оптимално кодиране.

Основополагаща характеристика на оптималното кодиране е статистиката на източника на информация (съобщения). Също така трябва да се спомене, че в методите, които ще бъдат разгледани в следващите редове, съобщенията на източника, които биват последователност от букви (символи), се кодират в последователност от двоични символи (0 и 1) – т.е. представянето с букви се заменя с представяне с нули и единици.

Отчитайки статистическите свойства на източника, може да се минимизира средният брой на двоичните символи, нужни за изразяване на една буква на съобщението така, че при отсъствие на шум е възможно да се намали времето за предаване или обемът на запаметяващите устройства, в които се съхранява информацията.

К. Шанон е доказал в една от своите теореми, че съобщенията, съставени от букви на някаква азбука z_i , може да се закодира (кодира) така, че средният брой на двоичните символи на една буква l_{cp} да бъде близко до ентропията на източника на тези символи H , но не по-малка от тази величина:

$$l_{\text{cp}} = \sum_{i=1}^k p(z_i) n(z_i) \geq H = -\sum_{i=1}^k p(z_i) \log p(z_i) \quad (1)$$

където $n(z_i)$ е броят на двоичните знаци, чрез които се представя буквата z_i , а $p(z_i)$ е вероятността за поява на буквата z_i .

Кодирането е оптимално тогава и само тогава, когато се изпълнява равенството

$$l_{\text{cp min}} = H \quad (2)$$

По принцип l_{cp} може да се получи различно от $l_{\text{cp min}}$, т.е., кодирането да не е напълно оптимално. За да се оцени степента на приближаване на получената l_{cp} до $l_{\text{cp min}}$, се въвежда параметърът *ефективност на кода* κ :

$$\kappa = \frac{l_{\text{cp min}}}{l_{\text{cp}}} = \frac{H}{l_{\text{cp}} \log_2 m} \quad (3)$$

или *излишък на кода* R_{κ} –

$$R_{\kappa} = 1 - \frac{l_{\text{cp min}}}{l_{\text{cp}}} \quad (4)$$

Методите, които ще разгледаме са два: *метод на Шанон-Фано* и *метод на Хафман*. За да бъдат по-добре изяснени, методите ще бъдат изложени чрез примери.

Метод на Шанон-Фано

Кодът на Шанон-Фано се образува по следния начин: буквите, от дадена азбука, на съобщение се записват в таблица в ред от най-високата към най-ниска вероятност на тяхната поява. Например, ако имаме източник на данни, който генерира само четири символа z_1 , z_2 , z_3 , и z_4 , имащи съответно вероятности за поява $p(z_1) = 0.25$, $p(z_2) = 0.125$, $p(z_3) = 0.50$, и $p(z_4) = 0.125$, подредбата на тези символи (букви) за този метод на оптимално кодиране е следната

z_i	$p(z_i)$
z_3	0.50
z_1	0.25
z_2	0.125
z_4	0.125

След това, символите се разделят на две групи така, че сумите от вероятностите във всяка от групите да бъдат по възможност равни, т.е. за горния случай ще имаме следното разделение.

z_i	$p(z_i)$
z_3	0.50
z_1	0.25
z_2	0.125
z_4	0.125

(Забележка: Трябва да се отбележи това, че само съседни по отношение на подредбата букви могат да бъдат заделени в група (или подгрупа). Освен това буквите (символите) z_i с еднаква вероятност за поява $p(z_i)$ се кодират с двоични последователности имащи един и същи брой двоични знаци. За да се изпълни това е нужно тези букви да се установяват в една и съща група (и подгрупа) при процеса на разделяне. Това не винаги е възможно, но е нужно човек да се стреми да го изпълнява.)

Всички букви от горната група в качество на първи символ приемат 1, а всички от долната група (половина) получават 0.

z_i	$p(z_i)$	I стъпка
z_3	0.50	1
z_1	0.25	0
z_2	0.125	0
z_4	0.125	0

С цел в последствие да имаме еднозначно декодиране, всеки един символ z_i трябва да бъде представян с различни двоични знаци, последователности. В тази връзка е нужно втората група от горната таблица да бъде допълнително разделена пак на две части (подгрупи), като сумите от вероятностите във всяка от тези части да бъдат по възможност равни. Както в горната стъпка, горната част приема двоичен символ 1 и долната част приема символ 0. Следователно получаваме

z_i	$p(z_i)$	I стъпка	II стъпка
z_3	0.50	1	
z_1	0.25	0	1
z_2	0.125	0	0
z_4	0.125	0	0

Този процес се повтаря до тогава, когато във всяка подгрупа остане по една буква (символ). В крайна сметка за разглеждания пример имаме

z_i	$p(z_i)$	I стъпка	II стъпка	III стъпка	$n(z_i)$
z_3	0.50	1			1
z_1	0.25	0	1		2
z_2	0.125	0	0	1	3
z_4	0.125	0	0	0	3

Това води до кодиране на символите z_i :

$$z_1 \rightarrow 01, z_2 \rightarrow 001, z_3 \rightarrow 1, z_4 \rightarrow 000$$

За да разберем дали кодирането е напълно оптимално, ще проверим дали уравнение (2) се изпълнява за този случай. За тази цел изчисляваме l_{cp} и H

$$l_{cp} = \sum_{i=1}^4 p(z_i) n(z_i) = 0.25 \cdot 2 + 0.125 \cdot 3 + 0.5 \cdot 1 + 0.125 \cdot 3 = 1.75$$

$$H = \sum_{i=1}^4 p(z_i) \log_2 p(z_i) = 0.25 \log_2 0.25 + 0.125 \log_2 0.125 + 0.5 \log_2 0.5 + 0.125 \log_2 0.125 = 1.75$$

По този начин, ние доказваме, че извършеното кодиране в примера е оптимално.

При оптимално кодиране от този тип е валидно следното:


Най-голям ефект се получава в случая, когато вероятностите на буквите представляват целочислени отрицателни степени на двойката – средният брой на символите на една буква в този случай е равен точно на ентропията. (Освен това оптималност се получава, когато сумите от вероятностите във всяка от групите, на които се разделят буквите, са равни. Това е следствие на факта, че вероятностите за поява на буквите са целочислени отрицателни степени на двойката.)

Табл. 1

Символ x_i	Кодова комбинация
x_1	1 1 1
x_2	1 0
x_3	1 1 0
x_4	0

Декодиране на данните, подложени на алгоритъма на Шенон-Фано

След получаването на таблицата с кодове табл. 1, пристъпваме към конструиране на декодиращото дърво на Шенон-Фано. То се използва, за да можем еднозначно да извличаме символи от потока входящи двоични букви. За получената таблица със символи и кодове, декодиращото дърво изглежда така:




Ако приемем, че в приемната част на една комуникационна система е приета последователността от двоични символи (букви)

10011001111001101010001110,

процесът на декодиране е следният.

1. Избира се първия (от ляво надясно) двоичен символ. — 10011001111001101010001110
2. Проследява се горното декодиращо дърво (от горе надолу) и се следи за това, дали някой от данните символи (x_i) съответства на тази двоична буква.
3. Ако съответства, то двоичния символ се заменя със съответния даннов символ. (В този случай даннов символ кодиран с '1' не съществува).
4. Ако няма даннов символ кодиран с дадения двоичен символ заемаме и следващия двоичен знак от последователността и формираме двоична дума, т.е. 10011001111001101010001110. (двоичната дума е '10').
5. Изпълняваме отново стъпка 2 – проследява се отново декодиращото дърво, с цел да намерим даннов символ кодиран с формираната в стъпка 4 двоична дума. В този случай е намерен даннов символ кодиран с '10' (това е символ x_2):



Следователно двоичната комбинация '10' в двоичната последователност се заменя с дадения даннов символ:

$x_2 0110011111001101010001110$.

6. Използвайки стъпки 1-5, ние продължаваме с декодирането на останалата част от последователността, като започваме с избиране на първия от ляво на дясно двоичен символ на новата двоична последователност (както в стъпка 1).

(Забележка: Стъпките 2 и 4 могат да се повторят повече от 2 пъти, както е показано по-горе.)

Алгоритъмът на Хафман е по-съвършен от този на Шенон-Фано и чрез него се получава винаги възможно най-ефективният код. При използване на алгоритъма на Шенон-Фано понякога възниква известна неопределеност и нееднозначност при разделянето на подгрупи, сумарните вероятности в които не могат да се изравнят, тъй като може или горната подгрупа, или долната да се направи с малко по-голяма или по-малка вероятност. При метода на Хафман такава неопределеност не съществува.

Кодирането по метода на Хафман става така. Символите се написват по реда на намаление на техните вероятности. След това двата най-малко вероятни символа се групират, като се взема сумарната им вероятност, и отново се извършва подреждане на символите (последните два най-малко вероятни се разглеждат като един) по намалението на техните вероятности. Тази процедура се повтаря, докато се получи сумарна вероятност единица. Пример за изпълнението на процедурата е даден в табл. 2 за азбука, състояща се от 6 символа. След това се тръгва по обратен ред и на символите, чиито вероятности са дали по-голямата (горната) от двете последни вероятности (колона №4 от табл. 2), се приписва нула, а на останалите – единица. При следващата стъпка се вземат групите от предната колона (колона №3 в табл. 2) и по същия начин им се приписват 0 и 1. Това се повтаря, докато се стигне до първата колона.


Табл. 2

Таблица 5.5

x_i	p_i	Спомагателни колонии				
		1	2	3	4	5
x_1	0,3	0,3	0,3	→0,4	→0,6	→1
x_2	0,2	0,2	→0,3	0,3	0,4	
x_3	0,15	→0,2	0,2	0,3		
x_4	0,15	0,15	0,2			
x_5	0,10	0,15				
x_6	0,10	0,15				

Много по-нагледно се съставят кодовите комбинации чрез т. нар. *кодovo дърво*, което се строи по следния начин. От точка, съответстваща на вероятност единица, се начертават два клона (фиг. 1), съответстващи на двете вероятности от предпоследната колона на таблицата (в случая колона №4 от табл. 2). При това се приема на левите клонове да се приписва по-голямата вероятност, респ. единици, а на десните – по-малката, респ. нули. След това двата

клона се разклоняват в съответствие със съставните им вероятности от по-предната колона, приписват се единици на левите и нули на десните клонове и това продължава, докато се изчерпят възможностите за разклоняване, т.е. докато се стигне до вероятностите за поява на отделните символи. Кодовата комбинация за всеки символ се получава, като се обходи дървото (фиг. 1) от най-горната точка до точката, съответстваща на съответния символ. Полученият в примера код е даден в табл. 3. От нея се вижда, че и в този случай кодът е префиксен. При това кодиране вместо $l_{cp} = 3$ (каквото би се получило при използване на равномерен код) се получава $l_{cp} = 2,5$.



Фиг. 1

Табл. 3

x_i	Кодова комбинация		
x_1	1	0	
x_2	0	0	
x_3	1	1	0
x_4	1	1	1
x_5	0	1	0
x_6	0	1	1

Различно обяснение на метода на Хафман

Буквите на азбуката на източника на информация се записват в стълб по ред на техните вероятности за поява, както при метода на Шанон-Фано. Следователно, използвайки статистиката на източника представена в примера на горния метод, ние имаме подредба

z_i	$p(z_i)$
z_3	0.50
z_1	0.25
z_2	0.125
z_4	0.125

т.е. същата подредба на буквите, както в горния пример. Тук се използва същата статистика на източника с цел да се онагледят разликата в принципа на действие на двата метода. Кодирането базирано на метода на Хафман се изпълнява по следния начин:

Последните две букви (букви с най-малки вероятности за поява) се обединяват в една спомагателна буква, към която се приписва сумарната вероятност – сума от вероятностите на двете букви.

z_i	$p(z_i)$	
z_3	0.50	
z_1	0.25	
z_2	0.125	z'
z_4	0.125	0.25


Вероятностите на буквите, не участващи в обединението, и получената сумарна вероятност наново се разполагат отново от най-голямата към най-малката в допълнителен стълб, а последните две вероятности отново се обединяват.

z_i	$p(z_i)$	
z_3	0.50	
z_1	0.25	z''
z'	0.25	0.50

Процесът продължава до тогава, когато не получим единствена спомагателна буква с вероятност равна на единица.

z_i	$p(z_i)$	
z_3	0.50	z'''
z''	0.50	1

Следователно, целият процес може да се представи нагледно по следния начин



Фиг. 3. Присвояване на кодови последователности от буквите z_i .

По този начин, кодовите комбинации, които се присвояват от буквите z_1 , z_2 , z_3 , и z_4 са съответно двоичните последователности 01, 001, 1, 000.

Разгледаните два метода могат да се използват не само за двоични кодове, а и за кодове с произволна основа m . В такъв случай при кодиране по алгоритъма на Шенон-Фано символите се делят не на две подгрупи, а на m подгрупи със сравнително еднакви сумарни вероятности, а при кодиране по Хафман от всеки възел на кодовото дърво излизат по m клона.

II. ЗАДАЧИ

1. Извършете оптимално кодиране по гореизложените два метода на съобщението:

(Трите ви имена отделени с интервал)

[Забележка: Първо трябва да се определят вероятностите за поява на отделните букви (символи) в съобщението (интервалът между думите се брои за символ)]

Също така проверете дали извършеното от вас кодиране е оптимално (да се изчисли ефективността и излишъкът на кода (кодирането)). Ако не е оптимално, обяснете защо и възможно ли е да се извърши оптимално кодиране в този случай?

2. Извършете оптимално кодиране по гореизложените два метода на източник на информация, имащ следната статистика

z_i	$p(z_i)$
z_1	0.43
z_2	0.13
z_3	0.13
z_4	0.08
z_5	0.08
z_6	0.08
z_7	0.035
z_8	0.035

Проверете дали извършеното от вас кодиране е оптимално (да се изчисли ефективността и излишъкът на кода (кодирането)). Ако не е оптимално, обяснете защо и възможно ли е да се извърши оптимално кодиране в този случай?

Съгласно горното кодиране, декодирайте следната последователност:

10110011011110001001010111101110110110010101100111100100011000111110110001010