


Тема №4: Класификатор със смес от Гаусови функции. (Gaussian mixture models, GMM)

Цел на упражнението


В Тема 4 се разглежда генеративен класификатор, който използва параметричен модел представляващ смес от Гаусови функции за да изчисли функцията на плътността на разпределение на вероятността за всеки клас данни. По време на експлоатация на модела, се изчислява вероятността конкретен входен вектор да принадлежи на всеки от класовете. Класификатора взема решение въз основа на правилото на Бейс за класификация с минимален риск или с помощта на log-likelihood estimator.

Понятие за GMM

GMM методът все основава на допускането, че всяко разпределение на случайна променлива може да бъде описано с комбинация от Гаусови функции.



Фиг. 4.1. Класификатор със смес от Гаусови функции -- параметрично описание на функцията на плътността на разпределение на вероятността за един от класовете данни в едномерно пространство



Фиг. 4.2. Класификатор с опорни вектори – една двумерна Гаусова функция в двумерно пространство

$$\text{Normal}(\mathbf{x} \mid \mu, \Sigma) = \frac{1}{(2\pi)^2} \frac{1}{\det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mu)^T \Sigma (\mathbf{x} - \mu) \right\}$$

Пример за класификация с GMM

Нека да разгледаме пример за класификация в три класа {Versicolor, Virginica, Setosa}, така както са дефинирани от Фишер във файл „fisheriris.mat“. Всеки образец е описан с четири вида описатели (дескриптори):

- Petal_Width,
- Petal Length,
- Sepal Width,
- Sepal Length

За целите на визуализация в следния пример избираме да работим с два от тези описатели (двумерни обекти се визуализират интуитивно). За целта последователно ще избираме различни двойки от четирите описатели и ще визуализираме преди да извършим класификация.

Примерна реализация с MATLAB:

Визуализираме данните X в двумерна координатна система $X = [\text{meas}(:,1), \text{meas}(:,2)]$, които определят неговото местоположение в равнината.

```
clear all
% зареждаме набора данни на Фишер
load fisheriris

% дефинираме X да ползва два от четирите описателя
X = [meas(:,3), meas(:,2)];
%X = [meas(:,1), meas(:,2), meas(:,3), meas(:,4)]; % {1,2,3,4}

% Избираме един от класовете „Setosa“ за да създадем детектор
% за него {versicolor, virginica, setosa}
Y = ismember(species,'setosa'); %{versicolor, virginica, setosa}

% По случаен начин разделяме оригиналния набор данни на
% обучаващ набор и тестов набор в съотношение 3/4 към 1/4
% използвайки метода „stratified holdout“
P = cvpartition(Y,'Holdout',0.25);

% създаваме модел с Nin измерения и Ncomp Гаусови компоненти
Nin=size(X,2);
Ncomp=2;
mix=gmm(Nin,Ncomp,'diag');

% обучаваме с EM алгоритъма
options = foptions;
options(1) = 1;
options(3) = 0;
options(5) = 1;
options(14) = 100;
```

```

mix = gmmem(mix,X(P.training,:),options);

% Използваме модела за да обработим тестовия набор от данни
%Cp = gmmpost(mix,X(P.test,:));
% in0=find(Cp(:,1)>0.5);
% in1=find(Cp(:,2)>=0.5);

% Използваме модела за да обработим тестовия набор от данни
C = gmmactiv(mix,X(P.test,:));
inx1=find(C(:,1)>C(:,2));
inx0=find(C(:,2)>=C(:,1));

Clog(inx1)=boolean(1);
Clog(inx0)=boolean(0);

% Изчисляваме точността на класификация като броя верни решения
% към общия брой тестови вектори
Accuracy = 100*sum(Y(P.test)' == Clog)/P.TestSize %mis-
classification rate

% Изчисляваме матрицата на решенията на класификатора
% (confusion matrix)
conMat = confusionmat(Y(P.test)',Clog) % the confusion matrix

```

Задачи за изпълнение

Задача 1. Създайте GMM класификатор, който да разграничава биологичен вид „Versicolor“ от останалите видове представени в базата данни {Virginica и Setosa}. Изследвайте кой от четирите описатели е най-информативен за целите на класификацията. Сортирайте описателите според критерии „информативност“. Изследвайте кои комбинации от описатели са най-подходящи за разпознаване на „Versicolor“. Проверете дали степента на информативност на описателите е същата, когато се цели разпознаване на биологичен вид „Virginica“. Направете същото за „Setosa“.

Задача 2. Използвайки резултатите от Задача 1, сравнете успешността на класификатора при класификация в три класа {Versicolor, Virginica, Setosa} –използвайте критерии „точност на класификация“, която ще изчислите като средна стойност от главния диагонал на confusion matrix.

Задача 3. Създайте GMM класификатор, който да открива състояния означени като „диабет“. За целта създайте класификатор в два класа като използвайте данните от файл „diabetes.mat“. Сравнете получената точност на класификация с тази получена с MLP NN (лаб. упр. 1), PNN (лаб. упр. 2), и SVM (лаб упр. 3).

Задача 4. Използвайки GMM класификатора от Задача 3, проверете дали нормализация на данните до диапазона [0, 1] би помогнала за подобряване на точността при класификация. За целта разделете стойностите на всеки от описателите на максималната стойност.