

Тема №5: Регресионен анализ.
Линейна регресия с една независима променлива.

Цел на упражнението

В Тема 5 изясняваме обхвата на задачите решавани с помощта на регресивен анализ, като за целта разглеждаме принципите на *Линейната регресия с една независима променлива* и *Множествена линейна регресия* при която се използват няколко независими променливи които не са линейно свързани.

Понятие за регресионен анализ


По принцип, регресионният анализ следва да се възприема като изследване на свързаността и каузалността между променливи които можем да наблюдаваме. Регресионен анализ може да се направи с линейни или нелинейни модели на една или повече независими променливи.

Методите за регресионен анализ се основават на допускането, че търсената случайна променлива y е зависима от една или повече случайни променливи x , които можем да наблюдаваме. Регресионния модел цели да обясни (моделира, предскаже) изменението на зависимата променлива, например $y=f(x)$, използвайки знание за измененията на независимите променливи от които се състои векторът x . Ако независимите променливи са еднозначно свързани с измененията на зависимата променлива, моделът може да се използва за предсказване на стойности които още не са наблюдавани.

В теорията най-често се разглежда примерът с *Линейна регресия с една независима променлива*, поради лесното представяне и интуитивно разбиране на уравнението на правата линия. В общия случай, всяка аналитична нелинейна функция също може да бъде използвана като апроксимираща функция при регресионен анализ – например квадратична функция, логаритмична функция, експоненциална функция, или всяка друга непрекъсната функция.

Понятие за Линейна регресия с една независима променлива

Методите за регресионен анализ се основават на допускането, че търсената случайна променлива y е зависима от една или повече случайни променливи x , които можем да наблюдаваме. При линейната регресия с една независима променлива правим допълнителното допускане, че между y и x има някаква ясно изразена пропорционалност, която достатъчно добре може да се апроксимира с права линия. За всяко отделно наблюдение (виж Фиг. 5.1), отклонението от стойността предсказан от модела може да бъде означено с ε , при което истинската стойност е $y = y' + \varepsilon$, т.е. **Истинската стойност = обяснената с модел + грешката.**



Фиг. 5.1. Линейна регресия с една независима променлива

Пример за Линейна регресия с една независима променлива

Първо разглеждаме пример за Линейна регресия с една независима променлива.

Нека да допуснем че разполагаме с база данни „carsmall.mat“, в която за различни марки автомобили са предоставени следните 10 характеристики:

- 'Weight',
- 'Horsepower',
- 'Acceleration',
- 'Model',
- 'Cylinders',
- 'Model_Year',
- 'Displacement',
- 'Mfg',
- 'Origin'
- 'MPG'.

Задачата е да предскажем пробег на автомобил в мили с един галон гориво, 'MPG', като използваме за независима променлива една от останалите 9 известни характеристики на автомобила.


Примерна реализация с MATLAB:

За начало избираме 'Weight' за независима променлива по която да предсказваме пробег 'MPG'.

```
clear all
% зареждаме базата данни
load carsmall

% избираме теглото на автомобила „Weight“ за независима променлива
% посредством която да предскажем MPG и визуализираме
```

```
x1 = Weight;  
y = MPG;  
scatter(x1,y, 'filled');  
hold on  
  
% Изчисляваме коефициентите на регресионния модел  
X = [ones(size(x1)) x1];  
b = regress(y,X);  
  
% Визуализираме регресионния модел  
x1fit = min(x1):10:max(x1);  
[X1FIT] = meshgrid(x1fit);  
  
YFIT = b(1) + b(2)*X1FIT;  
plot(X1FIT,YFIT)  
xlabel('Weight')  
ylabel('MPG')  
  
% Изчисляваме сумарната квадратична грешка за регресионния модел  
I2=find(isnan(y)==0);  
Yc1=y(I2);  
Xc1=x1(I2);  
Yf=b(1)+b(2)*Xc1;  
D=sum((Yc1-Yf).^2)
```



Фиг. 5.2. Моделиране на зависимата променлива “MPG” чрез линейна регресия с независимата променлива „Weight”


Множествена линейна регресия с няколко независими променливи

Множествена линейна регресия -- когато има повече от една независима променлива, която може да се използва за да се обясни изменението на зависимата променлива. Следва да се спазва изискването независимите променливи x да не са линейно свързани. Тогава, множествената линейна регресия може да се дефинира като:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon$$

където k е броя на променливите или параметрите на модела.

На Фиг 5.3 е показана визуализация на регресионен модел с две независими променливи 'Weight' и 'Horsepower', които за настоящото разглеждане приемаме за независими една от друга.



Фиг. 5.3. Множествена линейна регресия с няколко независими променливи

Пример за Множествена линейна регресия с повече от една независими променливи

Нека да разгледаме отново задачата от примера по-горе за случая с повече от една независима променлива. Нека за целта да изберем първите две характеристики 'Weight' и 'Horsepower' за независими променливи.

Примерното решение на MATLAB следва логиката на примера за Линейна регресия с една независима променлива, но с малки изменения за добавяне на втората независима променлива:

```
load carsmall
x1 = Weight;
x2 = Horsepower; % Contains NaN data
y = MPG;

scatter3(x1,x2,y,'filled')
hold on
```

```
X = [ones(size(x1)) x1 x2 x1.*x2];  
b = regress(y,X) % Removes NaN data  
  
x1fit = min(x1):100:max(x1);  
x2fit = min(x2):10:max(x2);  
[X1FIT,X2FIT] = meshgrid(x1fit,x2fit);  
  
YFIT = b(1) + b(2)*X1FIT + b(3)*X2FIT + b(4)*X1FIT.*X2FIT;  
  
mesh(X1FIT,X2FIT,YFIT)  
xlabel('Weight')  
ylabel('Horsepower')  
zlabel('MPG')  
view(50,10)
```

Задачи за изпълнение

Задача 1. Предскажете пробег на автомобил в мили за един галон гориво, ‘MPG’, използвайки като независима променлива всяка една от известните характеристики на автомобила {‘Weight’, ‘Horsepower’, ‘Acceleration’, ‘Model’, ‘Cylinders’, ‘Model_Year’, ‘Displacement’, ‘Mfg’, ‘Origin’}. Изследвайте полезността на всяка от тези характеристики и определете коя е най-подходяща за предсказване на пробег на ‘MPG’ на автомобила.

Задача 2. За заданието по Задача 1, изследвайте различни двойки описатели и определете двойката, която е най-подходяща за предсказване на пробег на автомобила ‘MPG’.

Задача 3. За заданието по Задача 1, използвайте три независими променливи за предсказване на пробег на автомобила ‘MPG’.