


Тема №6: Класификация с дърво на решенията (Decision Tree for Classification)

Цел на упражнението

Целта на Тема 6 е да се покажат възможностите за класификация с дърво на решенията. Представени са възможностите за решаване на класификационни проблеми със средствата на MATLAB.

Понятие за дърво на решенията

Концептуално, дърво на решенията може да се разглежда като граф, във всеки възел на който се проверява стойността на даден дескриптор. Всяко разклонение на дървото представлява резултата от проверка, а всеки лист е етикет. В зависимост от резултата от проверката се извършва разклонение по един от клоновете на дървото. Тази процедура се повтаря отново следващия възел на дървото.



Фиг. 6.1. Класификатор с дърво на решенията

Пример за класификация с дърво на решенията

Нека да разгледаме пример за класификация в два класа, при който създаваме детектор за клас Versicolor спрямо клас други {Virginica, Setosa}, като използваме базата данни създадена от Фишер (файл „fisheriris.mat“). Всеки образец е описан с четири вида описатели (дескриптори):

- Petal_Width,
- Petal_Length,
- Sepal_Width,
- Sepal_Length

Примерна реализация с MATLAB:

```
% зареждаме набора данни на Фишер
load fisheriris

% дефинираме X да ползва два от четирите описателя
X = [meas(:,1) meas(:,2) meas(:,3) meas(:,4)];

% Избираме един от класовете „versicolor“ за да създадем детектор
% за него {versicolor, virginica, setosa}
Y = nominal(ismember(species,'versicolor'));

% По случаен начин разделяме оригиналния набор данни на
% обучаващ набор и тестов набор използвайки метода „stratified
holdout“
P = cvpartition(Y,'Holdout',0.25);

% Създаваме класификатор „дърво на решенията за класификация“
използвайки
% обучаващите данни и съответните етикети за класова принадлежност
CDTStruct=fitctree(X(P.training,:),Y(P.training));
view(CDTStruct,'mode','graph')

% Използваме класификатора за да обработим тестовия набор от данни
C = predict(CDTStruct,X(P.test,:));

% Изчисляваме грешката от класификация като броя на грешните
решения
% към общия брой тестови вектори (miss-classification rate)
errRate = 100*sum(Y(P.test)~= C)/P.TestSize
Accuracy = 100*sum(Y(P.test)== C)/P.TestSize

% Изчисляваме матрицата на решенията на класификатора
% (confusion matrix)
conMat = confusionmat(Y(P.test),C);
conMat
```

Задачи за изпълнение

Задача 1. Създайте класификатор с дърво на решенията, който да разграничава биологичен вид „Versicolor“ от останалите видове представени в базата данни {Virginica и Setosa}. Изследвайте кой от четирите описатели е най-информативен за целите на класификацията.

Задача 2. Проверете дали степента на информативност на описателите е същата, когато се цели разпознаване на биологичен вид „Virginica“. Направете същото за „Setosa“. Въз основа на резултатите от Задача 1 и Задача 2, сравнете успешността на класификатора, когато се използва като детектор за всеки един от трите класа {Versicolor, Virginica, Setosa} – използвайте критерии „точност на класификация“, която ще изчислите като средна стойност от главния диагонал на confusion matrix.

Задача 3. Създайте детектор с дърво на решенията, който да открива състояния означени като „диабет“. За целта използвайте данните от файл „diabetes.mat“.